

5. Calculation Brierley

Ex 1:

Count vector D_1 : (1, 0, 1, 1, 0)Count vector D_2 : (1, 1, 1, 1, 0)Count vector D_3 : (1, 0, 0, 1, 1)

Ex 2:

$$tf(cat, D_1) = \frac{1}{3}$$

$$tf(eats, D_1) = \frac{1}{3}$$

$$tf(fish, D_1) = \frac{1}{3}$$

$$T_{cat} = \sum_t tf(t, D_1)$$

$$= tf(cat, D_1) + tf(eats, D_1) + tf(fish, D_1)$$

$$= 1$$

Ans:

với $N = 3$

$$-idf(cat) = \log \frac{3}{2} \approx 0.477$$

$$-idf(dog) = \log \frac{3}{1} \approx 0.477$$

$$-idf(eats) = \log \frac{3}{2} \approx 0.477$$

$$-idf(fish) = \log \frac{3}{3} = 0$$

$$-idf(like) = \log \left(\frac{3}{1} \right) \approx 0.477$$

term fish có IDF thấp nhất vì
term fish xuất hiện ở cả 3 document

Ex 4:

$$\therefore tf-idf(cats, D_1)$$

$$= tf(cats, D_1) \cdot idf(cats)$$

$$= \frac{1}{3} \cdot 0,176 = 0,059$$

$$\therefore tf-idf(cats, D_1)$$

$$= tf(cats, D_1) \cdot idf(cats)$$

$$= \frac{1}{3} \cdot 0,176 \approx 0,059$$

$$\therefore tf-idf(fish, D_1) = \frac{1}{3} \cdot 0 = 0$$

$tf-idf(fish, D_1) = 0$ vì $idf(fish) = 0$
tức là fish xuất hiện ở cả 3 document. $tf-idf$ thì kết hợp quan trọng (đánh giá) với 1 term xuất hiện nhiều trong document đó nhưng ở quá phổ biến trong toàn bộ corpus.

Ex 5: $\cos(x, y) = \frac{2}{\sqrt{3} \cdot \sqrt{2}} \approx 0,816$

Cosine similarity ở đây là 2 vectơ chuẩn hoá ở 3 chiều tương đương với việc chia độ dài tổng là

Ex 6 Dự đoán.

- Document D_1 có ~~the~~ similarity cao nhất với truy vấn toàn văn với query.
- Document D_3 có similarity thấp nhất vì $\emptyset$ có từ nào cũng với query.
- Term medical và image. có giá trị IDF thấp nhất vì xuất hiện cả trong D_1 và D_2 .
- Nếu bỏ IDF chỉ sử dụng count vector thì ranking $\emptyset$ đổi, ranking k/c cosine similarity gần nhau hơn giữa D_1 và D_2 do $\emptyset$ phạt trong số của IDF.

6. Prediction.

- Prediction 1: Nếu corpus có 30K documents, vocabulary sẽ có khoảng 500K - 600K unique term? hay chia theo khoảng triệu. Có thể nhiều hơn ít hơn tùy theo cách chia.
- Prediction 2: TF-IDF và lựa sẽ sparse + Tỷ lệ zero entries có thể lên đến hơn 99%.
- Prediction 3: Các documents đúng đây hết quả tìm kiếm chưa chắc là documents nhiều nghĩa nhất, và 1 document nhiều từ cũng với query nhất.